

Mejoramiento de la Calidad de Mamografías: Comparación entre el Modelo EDSR y Métodos de Interpolación Convencional en la Presencia de Ruido Gaussiano

Eylen Jhuliana Mercado Ontiveros
Instituto Nacional de Telecomunicaciones
Minas Gerais, Brasil
eylen.ontiveros@mtel.inatel.br

Abstract—Reducir la radiación en las mamografías es crucial para minimizar los riesgos para los pacientes sin comprometer la calidad de las imágenes. Este estudio compara un modelo de Super-Resolución basado en Deep Learning (EDSR) con métodos convencionales de interpolación para mejorar la calidad de mamografías de baja resolución, tanto en condiciones ideales como en presencia de ruido gaussiano. Los resultados muestran que aunque la interpolación convencional puede tener buenos resultados en la mejora de la resolución de imágenes sin ruido, el EDSR demuestra una mayor robustez en condiciones de ruido, manteniendo valores de SSIM comparables.

Index Terms—Super-Resolución, Mamografías, Interpolación, EDSR, Ruido Gaussiano, PSNR, SSIM

I. INTRODUCCIÓN

El cáncer de mama es una de las principales causas de mortalidad entre las mujeres a nivel mundial. Las mamografías son la herramienta más efectiva para la detección temprana de esta enfermedad, permitiendo identificar tumores en etapas iniciales [1]. La calidad en las imágenes mamográficas es crucial para una detección y diagnóstico eficaz. Por tanto tener una alta resolución en las imágenes mamográficas es esencial. Sin embargo, las mamografías requieren la exposición a radiación ionizante, lo que puede aumentar el riesgo de cáncer secundario y otros efectos adversos [2].

Los tejidos mamarios, al ser radiosensibles, son especialmente susceptibles a estos efectos debido a su composición celular activa y a su capacidad para proliferar y cambiar durante diferentes etapas de la vida, como el embarazo y la lactancia [3]. La exposición repetida a la radiación, como la que se produce con las mamografías frecuentes, puede aumentar el riesgo de efectos adversos en el tejido mamario [4], aunque en la mayoría de los casos los beneficios de la detección precoz del cáncer de mama superan este riesgo. No obstante, es importante tener en cuenta estos factores a la hora de tomar decisiones sobre la frecuencia y la necesidad de un estudio mamográfico.

La reducción de la dosis de radiación en mamografías sin comprometer la calidad de la imagen es un desafío crítico. Las imágenes de baja dosis tienden a tener una resolución inferior y mayor ruido, lo que puede dificultar la detección

precisa de anomalías [5]. En este contexto, la super-resolución basada en aprendizaje profundo ha emergido como una técnica prometedora para mejorar la calidad de las imágenes médicas [6].

El modelo Enhanced Deep Super-Resolution (EDSR) es una red neuronal convolucional avanzada que ha demostrado resultados sobresalientes en la mejora de la resolución de imágenes [7]. A diferencia de los métodos de interpolación convencionales, que pueden introducir artefactos y no son robustos frente al ruido, el EDSR puede aprender características complejas de las imágenes, mejorando significativamente la calidad visual y la precisión diagnóstica [8].

El presente estudio compara el desempeño del modelo EDSR con métodos de interpolación convencionales, como el vecino más cercano, lineal, cúbica y Lanczos4, en la mejora de la resolución de mamografías de baja resolución con y sin la presencia de ruido gaussiano. Evaluamos la calidad de las imágenes mejoradas utilizando el pico de relación señal-ruido (PSNR) y el índice de similitud estructural (SSIM) [9]. Los resultados obtenidos proporcionan una visión comprensiva de las ventajas y limitaciones de cada enfoque, destacando el potencial del EDSR para aplicaciones clínicas en la reducción de dosis de radiación.

• Contribuciones Principales:

- Comparación detallada entre el modelo EDSR y métodos de interpolación convencionales en la mejora de la resolución de mamografías.
- Evaluación del impacto del ruido gaussiano en la calidad de las imágenes mejoradas.
- Análisis de las implicaciones clínicas de utilizar modelos de super-resolución basados en aprendizaje profundo en mamografías de baja dosis.

Este artículo está organizado de la siguiente manera: la Sección II describe los datos y la metodología utilizada, la Sección III presenta los experimentos y resultados, la Sección IV discute los hallazgos y sus implicaciones, y la Sección V concluye con las contribuciones del estudio y futuras direcciones de investigación.

II. METODOLOGÍA

A. Dataset

Para este estudio, se utilizó el conjunto de datos de mamografías MIAS (Mammographic Image Analysis Society), disponible en Kaggle [10]. Este conjunto de datos contiene 322 imágenes mamográficas de mujeres con edades comprendidas entre 50 y 65 años. Las imágenes están en formato PGM y tienen una resolución de 1024x1024 píxeles. Cada imagen está etiquetada con información relevante, incluyendo la densidad del tejido mamario y la presencia de anomalías, como masas y calcificaciones.

El conjunto de datos MIAS es ampliamente utilizado en la investigación de análisis de imágenes mamográficas debido a su accesibilidad y la variedad de condiciones mamográficas que presenta [11]. Este conjunto de datos incluye diferentes tipos de densidades mamarias, clasificadas como grasa, densa o extremadamente densa, lo que permite evaluar el desempeño de los modelos en diversas condiciones de imagen.

B. Preparación de los Datos

Las imágenes fueron normalizadas y convertidas a escala de grises para simplificar el procesamiento. Para simular las condiciones de baja resolución, las imágenes fueron reducidas en tamaño utilizando la interpolación bilineal. Posteriormente, se añadió ruido gaussiano con una desviación estándar de 0.03 para evaluar la robustez de los modelos frente al ruido.



Fig. 1: Ejemplos de mamografías originales (izquierda), imágenes de baja resolución x4 (centro), e imágenes de baja resolución con ruido gaussiano (derecha).

C. Modelo EDSR

El modelo Enhanced Deep Super-Resolution (EDSR) es una variante mejorada de las redes neuronales residuales profundas, diseñada específicamente para la tarea de super-resolución de imágenes. Propuesto por Lim et al. [7], el EDSR ha demostrado ser una de las arquitecturas más efectivas para mejorar la resolución de imágenes, superando a muchos de los métodos tradicionales y otros modelos basados en aprendizaje profundo.

El EDSR elimina las capas de normalización por lotes (Batch Normalization) presentes en los bloques residuales estándar, lo que reduce el consumo de memoria y mejora la calidad de la imagen resultante. La arquitectura del EDSR consta de múltiples bloques residuales, cada uno compuesto por dos capas convolucionales y una función de activación ReLU. La salida de cada bloque se suma a su entrada original,




Fig. 2: Arquitectura del modelo EDSR.

permitiendo un aprendizaje más eficiente de características de alto nivel.

El EDSR se entrena utilizando un gran conjunto de datos de imágenes de alta resolución y sus correspondientes versiones de baja resolución generadas artificialmente. El objetivo del entrenamiento es minimizar la pérdida de error cuadrático medio (MSE) entre las imágenes de alta resolución originales y las imágenes de alta resolución generadas por el modelo.

Para este estudio, se utilizó las versiones preentrenada del modelo EDSR con un factor de escalado de 2x y 4x, disponible en la biblioteca EDSR Tensorflow [7]. El uso de un modelo preentrenado permite aprovechar las características aprendidas de un gran conjunto de datos de entrenamiento, lo que es particularmente útil cuando se dispone de recursos computacionales limitados.

D. Inferencia con el Modelo EDSR

El proceso de inferencia con el modelo EDSR implica los siguientes pasos:

- 1) **Preprocesamiento:** Las imágenes de baja resolución se normalizan y se convierten a formato tensorial compatible con TensorFlow.
- 2) **Super-Resolución:** Las imágenes preprocesadas se pasan a través del modelo EDSR para generar imágenes de alta resolución.
- 3) **Postprocesamiento:** Las imágenes generadas se desnormalizan y se convierten de nuevo a formato de imagen.

En este estudio, se evaluaron 10 imágenes de mamografías de baja resolución con y sin ruido gaussiano utilizando el modelo EDSR. Los resultados se compararon con las imágenes originales de alta resolución y con las imágenes generadas mediante métodos de interpolación convencionales.

E. Métodos de Interpolación

La interpolación de imágenes es un proceso utilizado para estimar nuevos valores de píxeles en una imagen con el fin de aumentar su resolución. En este estudio, se utilizaron cuatro métodos de interpolación convencionales disponibles en OpenCV:

- 1) **Interpolación Nearest Neighbor:** La interpolación Nearest Neighbor es el método más sencillo y rápido,

que asigna a cada nuevo píxel el valor del píxel más cercano en la imagen original. Aunque es computacionalmente eficiente, este método puede producir imágenes de menor calidad con bordes dentados.

- 2) **Interpolación Bilinear:** La interpolación Bilinear considera los cuatro píxeles más cercanos al píxel de destino y calcula el valor del nuevo píxel como una ponderación lineal de estos valores. Este método produce imágenes más suaves en comparación con el Nearest Neighbor, pero puede introducir un cierto desenfocado.
- 3) **Interpolación Bicubic:** La interpolación Bicubic utiliza 16 píxeles vecinos para estimar el valor del nuevo píxel, aplicando una interpolación cúbica en dos dimensiones. Este método suele proporcionar una mejor calidad de imagen que la interpolación bilinear, con transiciones más suaves y menos artefactos de borde.
- 4) **Interpolación Lanczos4:** La interpolación Lanczos4 emplea una función de sinc truncada para realizar la interpolación, considerando un vecindario de 8x8 píxeles. Este método es más complejo y computacionalmente intensivo, pero puede producir imágenes de muy alta calidad con detalles bien preservados.

F. Evaluación de Calidad

Para evaluar la calidad de las imágenes generadas, se utilizaron dos métricas ampliamente reconocidas: el pico de relación señal-ruido (PSNR) y el índice de similitud estructural (SSIM) [9]. El PSNR mide la calidad de la reconstrucción de la imagen comparando la imagen generada con la imagen original, mientras que el SSIM evalúa la similitud perceptual entre las dos imágenes, teniendo en cuenta factores como la luminancia, el contraste y la estructura.

- **PSNR:** Se calcula como:

$$PSNR = 10 \log_{10} \left(\frac{MAX_I^2}{MSE} \right) \quad (1)$$

donde MAX_I es el valor máximo de la intensidad de la imagen y MSE es el error cuadrático medio entre la imagen original y la generada.

- **SSIM:** Se calcula mediante:

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (2)$$

donde μ_x y μ_y son las medias de las imágenes x e y , σ_x^2 y σ_y^2 son las varianzas, σ_{xy} es la covarianza entre las imágenes, y C_1 y C_2 son constantes para estabilizar la división.

Los resultados experimentales mostraron que el modelo EDSR mantiene casi constante los valores de PSNR y SSIM en imágenes con y sin presencia de ruido gaussiano, a diferencia de los métodos de interpolación convencionales que en imágenes con presencia de ruido tienden a tener un menor desempeño en términos de PSNR y SSIM.

III. EXPERIMENTOS Y RESULTADOS

A. Justificación del Experimento

El objetivo principal de nuestro experimento es evaluar si los métodos de superresolución basados en aprendizaje profundo, como el EDSR, pueden mantener o mejorar la calidad de las imágenes mamográficas obtenidas con menores niveles de radiación, en comparación con los métodos de interpolación convencionales. Dado que las imágenes mamográficas son cruciales para la detección temprana del cáncer de mama, es esencial que cualquier método de reducción de dosis no comprometa la calidad diagnóstica de las imágenes.

La comparación se realiza en dos escenarios: imágenes de baja resolución sin ruido y con ruido gaussiano (0.03). Esto nos permite evaluar la robustez de los métodos en condiciones más realistas donde el ruido puede ser introducido debido a la reducción de la dosis de radiación.

- **Superresolución mediante el modelo EDSR:** Utilizamos el modelo EDSR preentrenado para aumentar la resolución de las imágenes mamográficas en factores de x2 y x4.
- **Métodos de interpolación convencionales:** Aplicamos cuatro métodos de interpolación disponibles en OpenCV (Nearest, Linear, Cubic y Lanczos4) para mejorar la resolución de las mismas imágenes en factores de x2 y x4.

B. Resultados

Los resultados obtenidos de los experimentos se resumen en la Tabla [1] y [2]. Las tablas muestran los valores de PSNR y SSIM para cada método de superresolución en imágenes sin ruido y con ruido gaussiano de 0.03.

TABLE I: Valores PSNR y SSIM sin ruido para diferentes modelos

| 2*Modelo | Sin Ruido x2 | | Sin Ruido x4 | |
|----------|--------------|--------|--------------|--------|
| | PSNR | SSIM | PSNR | SSIM |
| EDSR | 10.92 | 0.7385 | 9.78 | 0.6336 |
| Nearest | 45 | 0.9876 | 40.67 | 0.9694 |
| Cubic | 43.5 | 0.988 | 39.24 | 0.9767 |
| Lanczos4 | 45.02 | 0.9893 | 39.33 | 0.9712 |
| Linear | 44.83 | 0.9903 | 39.33 | 0.9767 |

TABLE II: Valores PSNR y SSIM con ruido 0.03 para diferentes modelos

| 2*Modelo | Ruido 0.03 x2 | | Ruido 0.03 x4 | |
|----------|---------------|--------|---------------|--------|
| | PSNR | SSIM | PSNR | SSIM |
| EDSR | 9.78 | 0.6339 | 9.66 | 0.5506 |
| Nearest | 32.8 | 0.5785 | 30.85 | 0.6012 |
| Cubic | 34.3 | 0.6001 | 32.17 | 0.6298 |
| Lanczos4 | 34.02 | 0.5801 | 31.96 | 0.6091 |
| Linear | 34.97 | 0.653 | 32.67 | 0.6703 |

En la figura 3 podemos observar el resultado de la inferencia mediante el modelo EDSR de una mamografía con proyección oblicua medio lateral, donde el modelo genera la imagen de 1024x1024 píxeles a partir de la imagen de baja resolución de tamaño 256x256 con ruido gaussiano de 0.03.



Fig. 3: Comparación de imágenes: a la izquierda la imagen original, en el centro la imagen de baja resolución con ruido y a la derecha la imagen de superresolución.

C. Análisis de los Resultados

Los resultados proporcionan una visión clara de las fortalezas y debilidades tanto del modelo EDSR como de los métodos de interpolación convencionales en el contexto de la superresolución de imágenes mamográficas.

Los métodos de interpolación convencionales, como Near-est, Linear, Cubic y Lanczos4, demostraron un rendimiento superior en términos de PSNR y SSIM en imágenes sin ruido. Esto se debe a que estos métodos están diseñados para realizar tareas de escalado de manera directa y eficiente, aprovechando la información existente en la imagen sin introducir nuevas inferencias. Sin embargo, su desempeño se vio significativamente afectado por la presencia de ruido gaussiano, lo que resalta su limitada capacidad para manejar la degradación de la calidad de la imagen.

Por otro lado, el modelo EDSR, aunque inicialmente superado por los métodos de interpolación en imágenes limpias, mostró una mayor robustez frente al ruido. Esta resiliencia se debe a la capacidad del EDSR para aprender representaciones de alta calidad de las imágenes de entrenamiento, permitiéndole reconstruir detalles finos y reducir el impacto del ruido. Sin embargo, la calidad del modelo EDSR también depende en gran medida de la cantidad y calidad de los datos de entrenamiento. Un modelo EDSR bien entrenado puede ofrecer mejoras significativas en la calidad de la imagen, especialmente en situaciones donde el ruido es un factor crítico.

IV. DISCUSIÓN

1) *Comparación y Relevancia:* La comparación entre EDSR y los métodos de interpolación pone de manifiesto una clara división en sus capacidades: mientras que los métodos de interpolación son efectivos para tareas de escalado simples y rápidas en entornos sin ruido, el EDSR sobresale en condiciones más adversas, donde la integridad de los detalles y la reducción de ruido son esenciales. Estos hallazgos son particularmente relevantes para el campo de la mamografía, donde la calidad de la imagen son cruciales. La capacidad del EDSR para mantener una alta calidad de imagen en presencia de ruido sugiere que, con un entrenamiento adecuado, podría ser una herramienta valiosa para mejorar las imágenes mamográficas obtenidas con dosis de radiación más bajas.

En resumen, los resultados de este estudio destacan la importancia de seleccionar el método adecuado para la superres-

olución de imágenes en función de las condiciones específicas de la tarea. Mientras que los métodos de interpolación pueden ser suficientes para escenarios de escalado directo sin ruido, el modelo EDSR ofrece una solución más robusta y efectiva para situaciones donde la reducción de ruido y la preservación de detalles finos son primordiales.

A. Limitaciones

Este estudio se limitó a un pequeño conjunto de datos y a un modelo EDSR preentrenado. Futuras investigaciones podrían explorar el entrenamiento de modelos específicos para mamografías y la evaluación en conjuntos de datos más grandes.

V. CONCLUSIONES

Este estudio se ha evaluado la efectividad del modelo EDSR frente a los métodos de interpolación convencionales para la superresolución de imágenes mamográficas, con y sin la presencia de ruido gaussiano. Los resultados indican que aunque los métodos de interpolación convencionales superan al modelo EDSR en imágenes sin ruido, el modelo EDSR muestra una mayor robustez y resiliencia en condiciones de ruido.

La capacidad del EDSR para mantener una calidad de imagen relativamente alta en situaciones ruidosas subraya su potencial para aplicaciones en las que la reducción de la dosis de radiación es crucial. Esto es particularmente relevante en el contexto de las mamografías, donde es esencial minimizar la exposición a la radiación sin comprometer la calidad de la imagen para la detección precisa del cáncer de mama.

No obstante, para aprovechar plenamente las capacidades del EDSR, es necesario un entrenamiento exhaustivo con grandes volúmenes de datos de alta calidad. El presente estudio proporciona una visión preliminar del rendimiento del modelo, y futuras investigaciones deberían centrarse en el entrenamiento y la optimización del EDSR con conjuntos de datos más amplios y variados.

En conclusión, aunque los métodos de interpolación convencionales pueden ser adecuados para tareas simples de escalado de imágenes, el EDSR ofrece una solución más robusta y eficaz para la superresolución de imágenes en entornos ruidosos, abriendo nuevas posibilidades para mejorar la calidad de las imágenes mamográficas y, en última instancia, contribuir a la reducción de la dosis de radiación en procedimientos de imagen médica.

A. Futuras Investigaciones

Futuras investigaciones podrían enfocarse en entrenar modelos específicos para mamografías, integrar técnicas de reducción de ruido y evaluar en conjuntos de datos más grandes y diversos. También podría ser utilizado como una herramienta de procesamiento en visualizadores DICOM para un mejor diagnóstico, entre muchas otras aplicaciones.

REFERENCES

- [1] R. A. Smith, S. W. Duffy, and R. Gabe, "Mammography screening: A summary of the evidence," *Radiologic clinics of North America*, vol. 40, no. 3, pp. 569–590, 2003.
- [2] V. A. McCormack and I. dos Santos Silva, "The role of mammographic density in breast cancer risk: evidence from biological and epidemiological studies," *International journal of cancer*, vol. 119, no. 4, pp. 728–739, 2006.
- [3] J. D. B. Jr and R. E. Shore, "Radiogenic breast cancer risks," *Radiation Research*, vol. 106, no. 2, pp. 180–194, 1986.
- [4] J. A. Harvey, R. E. Hendrick, and G. Collin, "Breast cancer screening: Benefits and harms," *The Breast Journal*, vol. 25, no. 2, pp. 127–134, 2019.
- [5] D. J. Brenner and E. J. Hall, "The risk of cancer from diagnostic x-rays," *The Lancet*, vol. 360, no. 9330, pp. 495–501, 2002.
- [6] X. Wang, K. Yu, S. Wu, J. Gu, Y. Liu, C. Dong, Y. Qiao, and C. Change Loy, "Esrgan: Enhanced super-resolution generative adversarial networks," *arXiv preprint arXiv:1809.00219*, 2018.
- [7] B. Lim, S. Son, H. Kim, S. Nah, and K. M. Lee, "Enhanced deep residual networks for single image super-resolution," in *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*, 2017, pp. 136–144.
- [8] C. Ledig, L. Theis, F. Huszár, J. Caballero, A. Cunningham, A. Acosta, A. Aitken, A. Tejani, J. Totz, Z. Wang *et al.*, "Photo-realistic single image super-resolution using a generative adversarial network," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 4681–4690.
- [9] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, "Image quality assessment: from error visibility to structural similarity," *IEEE transactions on image processing*, vol. 13, no. 4, pp. 600–612, 2004.
- [10] M. I. A. Society, "Mias mammography dataset," <https://www.kaggle.com/kmader/mias-mammography>, 2020.
- [11] J. Suckling, J. Parker, D. Dance, S. Astley, I. Hutt, C. Boggis, I. Ricketts, E. Stamatakis, N. Cerneaz, S. Kok *et al.*, "The mammographic image analysis society digital mammogram database," *Excerpta Medica. International Congress Series*, vol. 1069, pp. 375–378, 1994.