

# Melhoria da Qualidade de Mamografias: Comparação entre o Modelo EDSR e Métodos de Interpolação Convencional na Presença de Ruído Gaussiano

Eylen Jhuliana Mercado Ontiveros  
*Instituto Nacional de Telecomunicações*  
Minas Gerais, Brasil  
eylen.ontiveros@mtel.inatel.br

**Abstract**—Reduzir a radiação nas mamografias é crucial para minimizar os riscos para os pacientes sem comprometer a qualidade das imagens. Este estudo compara um modelo de Super-Resolução baseado em Deep Learning (EDSR) com métodos convencionais de interpolação para melhorar a qualidade de mamografias de baixa resolução, tanto em condições ideais quanto na presença de ruído gaussiano. Os resultados mostram que, embora a interpolação convencional possa ter bons resultados na melhoria da resolução de imagens sem ruído, o EDSR demonstra uma maior robustez em condições de ruído, mantendo valores de SSIM comparáveis.

**Index Terms**—Super-Resolução, Mamografias, Interpolação, EDSR, Ruído Gaussiano, PSNR, SSIM

## I. INTRODUÇÃO

O câncer de mama é uma das principais causas de mortalidade entre as mulheres a nível mundial. As mamografias são a ferramenta mais eficaz para a detecção precoce desta doença, permitindo identificar tumores em estágios iniciais [1]. A qualidade nas imagens mamográficas é crucial para uma detecção e diagnóstico eficazes. Portanto, ter uma alta resolução nas imagens mamográficas é essencial. No entanto, as mamografias requerem a exposição à radiação ionizante, o que pode aumentar o risco de câncer secundário e outros efeitos adversos [2].

Os tecidos mamários, por serem radiosensíveis, são especialmente suscetíveis a esses efeitos devido à sua composição celular ativa e à sua capacidade de proliferar e mudar durante diferentes etapas da vida, como a gravidez e a lactação [3]. A exposição repetida à radiação, como a que ocorre com mamografias frequentes, pode aumentar o risco de efeitos adversos no tecido mamário [4], embora na maioria dos casos os benefícios da detecção precoce do câncer de mama superem esse risco. No entanto, é importante levar em consideração esses fatores ao tomar decisões sobre a frequência e a necessidade de um estudo mamográfico.

A redução da dose de radiação em mamografias sem comprometer a qualidade da imagem é um desafio crítico. As imagens de baixa dose tendem a ter uma resolução inferior e maior ruído, o que pode dificultar a detecção precisa de anomalias [5]. Nesse contexto, a super-resolução baseada em

aprendizado profundo emergiu como uma técnica promissora para melhorar a qualidade das imagens médicas [6].

O modelo Enhanced Deep Super-Resolution (EDSR) é uma rede neural convolucional avançada que tem demonstrado resultados excepcionais na melhoria da resolução de imagens [7]. Ao contrário dos métodos de interpolação convencionais, que podem introduzir artefatos e não são robustos frente ao ruído, o EDSR pode aprender características complexas das imagens, melhorando significativamente a qualidade visual e a precisão diagnóstica [8].

O presente estudo compara o desempenho do modelo EDSR com métodos de interpolação convencionais, como o vizinho mais próximo, linear, cúbica e Lanczos4, na melhoria da resolução de mamografias de baixa resolução com e sem a presença de ruído gaussiano. Avaliamos a qualidade das imagens melhoradas utilizando o pico de relação sinal-ruído (PSNR) e o índice de similaridade estrutural (SSIM) [9]. Os resultados obtidos proporcionam uma visão abrangente das vantagens e limitações de cada abordagem, destacando o potencial do EDSR para aplicações clínicas na redução de doses de radiação.

### • Contribuições Principais:

- Comparação detalhada entre o modelo EDSR e métodos de interpolação convencionais na melhoria da resolução de mamografias.
- Avaliação do impacto do ruído gaussiano na qualidade das imagens melhoradas.
- Análise das implicações clínicas de utilizar modelos de super-resolução baseados em aprendizado profundo em mamografias de baixa dose.

Este artigo está organizado da seguinte maneira: a Seção II descreve os dados e a metodologia utilizada, a Seção III apresenta os experimentos e resultados, a Seção IV discute as descobertas e suas implicações, e a Seção V conclui com as contribuições do estudo e futuras direções de pesquisa.

## II. METODOLOGIA

### A. Dataset

Para este estudo, utilizou-se o conjunto de dados de mamografias MIAS (Mammographic Image Analysis Society), disponível no Kaggle [10]. Este conjunto de dados contém 322 imagens mamográficas de mulheres com idades compreendidas entre 50 e 65 anos. As imagens estão em formato PGM e têm uma resolução de 1024x1024 pixels. Cada imagem está etiquetada com informações relevantes, incluindo a densidade do tecido mamário e a presença de anomalias, como massas e calcificações.

O conjunto de dados MIAS é amplamente utilizado na pesquisa de análise de imagens mamográficas devido à sua acessibilidade e à variedade de condições mamográficas que apresenta [11]. Este conjunto de dados inclui diferentes tipos de densidades mamárias, classificadas como gordura, densa ou extremamente densa, o que permite avaliar o desempenho dos modelos em diversas condições de imagem.

### B. Preparação dos Dados

As imagens foram normalizadas e convertidas para escala de cinza para simplificar o processamento. Para simular as condições de baixa resolução, as imagens foram reduzidas em tamanho utilizando a interpolação bilinear. Posteriormente, foi adicionado ruído gaussiano com um desvio padrão de 0.03 para avaliar a robustez dos modelos frente ao ruído.



Fig. 1: Exemplos de mamografias originais (esquerda), imagens de baixa resolução x4 (centro), e imagens de baixa resolução com ruído gaussiano (direita).

### C. Modelo EDSR

O modelo Enhanced Deep Super-Resolution (EDSR) é uma variante melhorada das redes neurais residuais profundas, projetada especificamente para a tarefa de super-resolução de imagens. Proposto por Lim et al. [7], o EDSR tem demonstrado ser uma das arquiteturas mais eficazes para melhorar a resolução de imagens, superando muitos dos métodos tradicionais e outros modelos baseados em aprendizado profundo.

O EDSR elimina as camadas de normalização por lotes (Batch Normalization) presentes nos blocos residuais padrão, o que reduz o consumo de memória e melhora a qualidade da imagem resultante. A arquitetura do EDSR consiste em múltiplos blocos residuais, cada um composto por duas camadas convolucionais e uma função de ativação ReLU. A saída de cada bloco é somada à sua entrada original, permitindo um aprendizado mais eficiente de características de alto nível.




Fig. 2: Arquitetura do modelo EDSR.

O EDSR é treinado utilizando um grande conjunto de dados de imagens de alta resolução e suas correspondentes versões de baixa resolução geradas artificialmente. O objetivo do treinamento é minimizar a perda de erro quadrático médio (MSE) entre as imagens de alta resolução originais e as imagens de alta resolução geradas pelo modelo.

Para este estudo, utilizou-se a versão pré-treinada do modelo EDSR com um fator de escalonamento de 2x e 4x, disponível na biblioteca EDSR Tensorflow [7]. O uso de um modelo pré-treinado permite aproveitar as características aprendidas de um grande conjunto de dados de treinamento, o que é particularmente útil quando se dispõe de recursos computacionais limitados.

### D. Inferência com o Modelo EDSR

O processo de inferência com o modelo EDSR envolve os seguintes passos:

- 1) **Pré-processamento:** As imagens de baixa resolução são normalizadas e convertidas para formato tensorial compatível com TensorFlow.
- 2) **Super-Resolução:** As imagens pré-processadas são passadas através do modelo EDSR para gerar versões de alta resolução.
- 3) **Pós-processamento:** As imagens de alta resolução geradas são convertidas de volta para o formato de imagem e desnormalizadas para visualização.

Neste estudo, foram avaliadas 10 imagens de mamografias de baixa resolução com e sem ruído gaussiano utilizando o modelo EDSR. Os resultados foram comparados com as imagens originais de alta resolução e com as imagens geradas por métodos de interpolação convencionais.

### E. Interpolação Convencional

Os métodos de interpolação convencional foram implementados utilizando a biblioteca OpenCV. Os métodos avaliados incluem:

- **Interpolação Nearest Neighbor:** A interpolação Nearest Neighbor é o método mais simples e rápido, que atribui a cada novo pixel o valor do pixel mais próximo na imagem original. Embora seja computacionalmente eficiente, este

método pode produzir imagens de menor qualidade com bordas dentadas.

- **Interpolação Linear:** A interpolação Linear considera os quatro pixels mais próximos ao pixel de destino e calcula o valor do novo pixel como uma ponderação linear desses valores. Este método produz imagens mais suaves em comparação com o Nearest Neighbor, mas pode introduzir algum desfoque.
- **Interpolação Bicúbica:** A interpolação Bicúbica utiliza 16 pixels vizinhos para estimar o valor do novo pixel, aplicando uma interpolação cúbica em duas dimensões. Este método geralmente proporciona uma melhor qualidade de imagem do que a interpolação bilinear, com transições mais suaves e menos artefatos de borda.
- **Interpolação Lanczos4:** A interpolação Lanczos4 emprega uma função sinc truncada para realizar a interpolação, considerando um bairro de 8x8 pixels. Este método é mais complexo e computacionalmente intensivo, mas pode produzir imagens de muito alta qualidade com detalhes bem preservados.

#### F. Métricas de Avaliação

Para avaliar a qualidade das imagens geradas, se utilizaram as métricas amplamente reconhecidas: o pico de relação sinal-ruído (PSNR) e o índice de similaridade estrutural (SSIM) [9]. O PSNR mede a qualidade da reconstrução da imagem comparando a imagem gerada com a imagem original, enquanto o SSIM avalia a similaridade perceptual entre as duas imagens, levando em conta fatores como a luminância, o contraste e a estrutura.

- **PSNR:** É calculado como:

$$PSNR = 10 \log_{10} \left( \frac{MAX_I^2}{MSE} \right) \quad (1)$$

onde  $MAX_I$  é o valor máximo da intensidade da imagem e  $MSE$  é o erro quadrático médio entre a imagem original e a gerada.

- **SSIM:** É calculado por meio de:

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (2)$$

onde  $\mu_x$  e  $\mu_y$  são as médias das imagens  $x$  e  $y$ ,  $\sigma_x^2$  e  $\sigma_y^2$  são as variâncias,  $\sigma_{xy}$  é a covariância entre as imagens, e  $C_1$  e  $C_2$  são constantes para estabilizar a divisão.

Os resultados experimentais mostraram que o modelo EDSR mantém quase constantes os valores de PSNR e SSIM em imagens com e sem a presença de ruído gaussiano, ao contrário dos métodos de interpolação convencionais que, em imagens com presença de ruído, tendem a ter um desempenho inferior em termos de PSNR e SSIM.

### III. EXPERIMENTOS E RESULTADOS

#### A. Justificação do Experimento

O principal objetivo do nosso experimento é avaliar se os métodos de super-resolução baseados em aprendizado profundo, como o EDSR, podem manter ou melhorar a qualidade

das imagens mamográficas obtidas com menores níveis de radiação, em comparação com os métodos de interpolação convencionais. Dado que as imagens mamográficas são cruciais para a detecção precoce do câncer de mama, é essencial que qualquer método de redução de dose não comprometa a qualidade diagnóstica das imagens.

A comparação é realizada em dois cenários: imagens de baixa resolução sem ruído e com ruído gaussiano (0.03). Isso nos permite avaliar a robustez dos métodos em condições mais realistas onde o ruído pode ser introduzido devido à redução da dose de radiação.

- **Super-resolução através do modelo EDSR:** Utilizamos o modelo EDSR pré-treinado para aumentar a resolução das imagens mamográficas em fatores de x2 e x4.
- **Métodos de interpolação convencionais:** Aplicamos quatro métodos de interpolação disponíveis no OpenCV (Nearest, Linear, Cubic e Lanczos4) para melhorar a resolução das mesmas imagens em fatores de x2 e x4.

#### B. Resultados

Os resultados obtidos dos experimentos são resumidos nas Tabelas [1] e [2]. As tabelas mostram os valores de PSNR e SSIM para cada método de super-resolução em imagens sem ruído e com ruído gaussiano de 0,03.

TABLE I: Valores PSNR y SSIM sem ruído para diferentes modelos

2*Modelo	Sin Ruído x2		Sin Ruído x4	
	PSNR	SSIM	PSNR	SSIM
EDSR	10.92	0.7385	9.78	0.6336
Nearest	45	0.9876	40.67	0.9694
Cubic	43.5	0.988	39.24	0.9767
Lanczos4	45.02	0.9893	39.33	0.9712
Linear	44.83	0.9903	39.33	0.9767

TABLE II: Valores PSNR y SSIM com ruído 0.03 para diferentes modelos

2*Modelo	Ruído 0.03 x2		Ruído 0.03 x4	
	PSNR	SSIM	PSNR	SSIM
EDSR	9.78	0.6339	9.66	0.5506
Nearest	32.8	0.5785	30.85	0.6012
Cubic	34.3	0.6001	32.17	0.6298
Lanczos4	34.02	0.5801	31.96	0.6091
Linear	34.97	0.653	32.67	0.6703

Na figura 3, podemos observar o resultado da inferência utilizando o modelo EDSR em uma mamografia com projeção oblíqua médio-lateral, onde o modelo gera a imagem de 1024x1024 pixels a partir da imagem de baixa resolução de tamanho 256x256 com ruído gaussiano de 0,03.

#### C. Análise dos Resultados

Os resultados fornecem uma visão clara das forças e fraquezas tanto do modelo EDSR quanto dos métodos de interpolação convencionais no contexto da super-resolução de imagens mamográficas.

Os métodos de interpolação convencionais, como Nearest, Linear, Cubic e Lanczos4, demonstraram um desempenho



Fig. 3: Comparação de imagens: à esquerda, a imagem original; no centro, a imagem de baixa resolução com ruído; à direita, a imagem de super-resolução.

superior em termos de PSNR e SSIM em imagens sem ruído. Isso se deve ao fato de que esses métodos são projetados para realizar tarefas de escalonamento de maneira direta e eficiente, aproveitando as informações existentes na imagem sem introduzir novas inferências. No entanto, seu desempenho foi significativamente afetado pela presença de ruído gaussiano, o que destaca sua capacidade limitada para lidar com a degradação da qualidade da imagem.

Por outro lado, o modelo EDSR, embora inicialmente superado pelos métodos de interpolação em imagens limpas, mostrou uma maior robustez frente ao ruído. Essa resiliência se deve à capacidade do EDSR de aprender representações de alta qualidade das imagens de treinamento, permitindo-lhe reconstruir detalhes finos e reduzir o impacto do ruído. No entanto, a qualidade do modelo EDSR também depende em grande medida da quantidade e qualidade dos dados de treinamento. Um modelo EDSR bem treinado pode oferecer melhorias significativas na qualidade da imagem, especialmente em situações onde o ruído é um fator crítico.

#### IV. DISCUSSÃO

1) *Comparação e Relevância:* A comparação entre a EDSR e os métodos de interpolação revela uma clara divisão em seus capacidades: enquanto os métodos de interpolação são eficazes para tarefas de dimensionamento simples e rápidas em ambientes sem ruído, a EDSR se sobressai em condições mais adversas, em que a integridade dos detalhes e a redução de ruído são essenciais. Essas descobertas são particularmente relevantes para o campo da mamografia, onde a qualidade da imagem é crucial. A capacidade da EDSR de manter a alta qualidade da imagem na presença de ruído sugere que, com o treinamento adequado, ela pode ser uma ferramenta valiosa para melhorar as imagens mamográficas obtidas com doses mais baixas de radiação.

Em resumo, os resultados deste estudo destacam a importância de selecionar o método correto para a geração de imagens de super-resolução, dependendo das condições específicas da tarefa. Embora os métodos de interpolação possam ser suficientes para cenários de dimensionamento direto sem ruído, o modelo EDSR oferece uma solução mais robusta e eficaz para situações em que a redução de ruído e a preservação de detalhes finos são fundamentais.

#### A. Limitações

Este estudo foi limitado a um pequeno conjunto de dados e a um modelo EDSR pré-treinado. Pesquisas futuras poderiam explorar o treinamento e a avaliação de modelos específicos para mamografia em conjuntos de dados maiores.

#### V. CONCLUSÕES

Este estudo avaliou a eficácia do modelo EDSR em relação aos métodos de interpolação convencionais para a super-resolução de imagens mamográficas, com e sem a presença de ruído Gaussiano. Os resultados indicam que, embora os métodos de interpolação convencionais superem o modelo EDSR em imagens sem ruído, o modelo EDSR apresenta maior robustez e resiliência em condições de ruído.

A capacidade do EDSR de manter uma qualidade de imagem relativamente alta em situações ruidosas destaca seu potencial para aplicações em que a redução da dose de radiação é crucial. Isso é particularmente relevante no contexto da mamografia, em que minimizar a exposição à radiação sem comprometer a qualidade da imagem é essencial para a detecção precisa do câncer de mama.

No entanto, para explorar totalmente os recursos da EDSR, é necessário um treinamento extensivo com grandes volumes de dados de alta qualidade. O presente estudo fornece uma visão preliminar do desempenho do modelo, e pesquisas futuras devem se concentrar no treinamento e na otimização da EDSR com conjuntos de dados maiores e mais variados.

Concluindo, enquanto os métodos de interpolação convencionais podem ser adequados para tarefas simples de dimensionamento de imagens, o EDSR oferece uma solução mais robusta e eficiente para imagens de super-resolução em ambientes ruidosos, abrindo novas possibilidades para melhorar a qualidade das imagens mamográficas e, em última análise, contribuindo para a redução da dose de radiação em procedimentos de imagens médicas.

#### A. Futuras Investigaciones

Pesquisas futuras poderiam se concentrar no treinamento de modelos específicos para mamografia, integrando técnicas de redução de ruído e avaliando conjuntos de dados maiores e mais diversificados. Ele também poderia ser usado como uma ferramenta de processamento em visualizadores DICOM para melhorar o diagnóstico, entre muitas outras aplicações.

#### REFERENCES

- [1] R. A. Smith, S. W. Duffy, and R. Gabe, "Mammography screening: A summary of the evidence," *Radiologic clinics of North America*, vol. 40, no. 3, pp. 569–590, 2003.
- [2] V. A. McCormack and I. dos Santos Silva, "The role of mammographic density in breast cancer risk: evidence from biological and epidemiological studies," *International journal of cancer*, vol. 119, no. 4, pp. 728–739, 2006.
- [3] J. D. B. Jr and R. E. Shore, "Radiogenic breast cancer risks," *Radiation Research*, vol. 106, no. 2, pp. 180–194, 1986.
- [4] J. A. Harvey, R. E. Hendrick, and G. Collin, "Breast cancer screening: Benefits and harms," *The Breast Journal*, vol. 25, no. 2, pp. 127–134, 2019.
- [5] D. J. Brenner and E. J. Hall, "The risk of cancer from diagnostic x-rays," *The Lancet*, vol. 360, no. 9330, pp. 495–501, 2002.

- [6] X. Wang, K. Yu, S. Wu, J. Gu, Y. Liu, C. Dong, Y. Qiao, and C. Change Loy, "Esrgan: Enhanced super-resolution generative adversarial networks," *arXiv preprint arXiv:1809.00219*, 2018.
- [7] B. Lim, S. Son, H. Kim, S. Nah, and K. M. Lee, "Enhanced deep residual networks for single image super-resolution," in *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*, 2017, pp. 136–144.
- [8] C. Ledig, L. Theis, F. Huszár, J. Caballero, A. Cunningham, A. Acosta, A. Aitken, A. Tejani, J. Totz, Z. Wang *et al.*, "Photo-realistic single image super-resolution using a generative adversarial network," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 4681–4690.
- [9] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, "Image quality assessment: from error visibility to structural similarity," *IEEE transactions on image processing*, vol. 13, no. 4, pp. 600–612, 2004.
- [10] M. I. A. Society, "Mias mammography dataset," <https://www.kaggle.com/kmader/mias-mammography>, 2020.
- [11] J. Suckling, J. Parker, D. Dance, S. Astley, I. Hutt, C. Boggis, I. Rick-  
etts, E. Stamatakis, N. Cerneaz, S. Kok *et al.*, "The mammographic  
image analysis society digital mammogram database," *Excerpta Medica. International Congress Series*, vol. 1069, pp. 375–378, 1994.